

**LAPORAN TUGAS MACHINE LEARNING
PREDIKSI KELULUSAN TEPAT WAKTU MAHASISWA
MENGUNAKAN DECISION TREE DAN NAIVE BAYES**



Disusun Oleh

Nama : Lio Kusnata
NPM : G1A023013
Kelas : A1

Dosen Pengampu

Ir. Arie Vatesia, S.T., M.T.I., Ph.D., IPP

**PROGRAM STUDI INFORMATIKA
FAKULTAS TEKNIK
UNIVERSITAS BENGKULU
2026**

SOAL DAN PEMBAHASAN

DESKRIPSI TUGAS

Kamu adalah seorang Data Scientist di startup EduTech. Perusahaan ingin memprediksi apakah mahasiswa akan LULUS TEPAT WAKTU atau TIDAK. Dataset mahasiswa_lulus.csv berisi 500 data dengan fitur IPK, Kehadiran, Jam_Belajar, Organisasi, Penghasilan_Ortu, Jenis_Kelamin, dan Status_Beasiswa. Tugas terdiri dari Bagian A: Analisis Konsep, Bagian B: Implementasi dan Evaluasi, serta Bagian C: Rekomendasi dan Etika.

BAGIAN A: ANALISIS KONSEP

1. Decision Tree dibandingkan Naive Bayes

Decision Tree lebih tepat digunakan apabila hubungan antara fitur dengan hasil kelulusan bersifat kompleks dan melibatkan kombinasi beberapa kondisi sekaligus. Contohnya, kemungkinan mahasiswa lulus tepat waktu dapat dipengaruhi oleh gabungan IPK, tingkat kehadiran, dan jam belajar; Decision Tree dapat membentuk aturan seperti “jika IPK tinggi dan kehadiran baik, maka kemungkinan lulus tepat waktu lebih besar”. Selain itu, hasilnya relatif mudah dipahami karena dapat direpresentasikan sebagai pohon keputusan dan aturan if-then.

Alasan kedua, Decision Tree tidak mensyaratkan setiap fitur saling independen. Beberapa variabel pada dataset ini berpotensi saling berkaitan, misalnya IPK dan Jam Belajar. Berbeda dari Naive Bayes yang mengasumsikan independensi antarfitur, Decision Tree tetap dapat menangani fitur yang saling berkorelasi tanpa mengurangi validitas aturan yang dibentuk.

2. Asumsi independensi pada Naive Bayes

Pasangan Naive Bayes mengasumsikan setiap fitur tidak bergantung satu sama lain terhadap kelas target. Dalam kondisi nyata, asumsi ini belum tentu terpenuhi, meskipun model masih dapat memberikan hasil yang cukup baik walau terdapat hubungan antarfitur.

IPK dan Jam Belajar mahasiswa dengan jam belajar lebih banyak berpotensi memperoleh IPK lebih tinggi, sehingga kedua variabel ini cenderung berkorelasi positif.

Status Beasiswa dan Penghasilan Ortu mahasiswa dari keluarga berpenghasilan rendah memiliki peluang lebih besar memperoleh beasiswa, sehingga kedua fitur ini juga saling berkaitan dan tidak sepenuhnya independen.

3. Risiko overfitting pada Decision Tree

Pohon Decision Tree berisiko overfitting terutama ketika pohon dibuat terlalu dalam. Pada dataset yang hanya berjumlah 500 data, pohon yang terlalu kompleks dapat mempelajari pola yang sangat spesifik pada data latih termasuk noise sehingga performa sangat baik pada data training namun menurun pada data baru. Hal ini konsisten dengan hasil pada Bagian B, di mana Decision Tree (depth=None) mencapai akurasi hampir sempurna pada data latih tetapi tidak lebih

unggul dibanding Decision Tree (depth=3) pada data uji.

Mitigasi yang dapat diterapkan antara lain pruning, membatasi max depth, menentukan min samples split dan min samples leaf, serta menggunakan cross-validation untuk mencari parameter terbaik. Perbandingan performa antara data training dan testing juga perlu dilakukan selisih yang besar menjadi indikasi overfitting.

BAGIAN B: IMPLEMENTASI DAN EVALUASI (KELOMPOK)

1. Preprocessing dan Pembangunan Model


Dataset mahasiswa_lulus.csv memiliki 500 observasi dan delapan kolom. Target Lulus_Tepat_Waktu terdiri atas 237 kelas Ya dan 263 kelas Tidak. Nilai hilang ditemukan pada IPK sebanyak 20, Kehadiran 25, Jam_Belajar 30, dan Penghasilan_Ortu 15. Fitur numerik diimputasi menggunakan median data latih, sedangkan fitur kategorik menggunakan modus. Organisasi, Penghasilan_Ortu, Jenis_Kelamin, dan Status_Beasiswa diubah menggunakan OneHotEncoder.

Data dibagi menjadi 400 data latih dan 100 data uji dengan rasio 80:20, stratifikasi target, serta random_state=42. Tiga model dilatih menggunakan pembagian data yang sama, yaitu DecisionTreeClassifier(max_depth=3), DecisionTreeClassifier(max_depth=None), dan GaussianNB. Seluruh proses preprocessing dimasukkan ke dalam pipeline sehingga parameter imputasi dan encoding hanya dipelajari berdasarkan data latih.

2. Hasil Evaluasi

Model	Akurasi	Precision	Recall	F1	Akurasi Latih
Decision Tree depth 3	0,77	0,74	0,79	0,76	0,78
Decision Tree penuh	0,69	0,69	0,62	0,65	1,00
Gaussian Naive Bayes	0,70	0,69	0,66	0,67	0,76


Tabel 1. Perbandingan performa tiga model.



Gambar 1. Perbandingan metrik evaluasi tiga model.

Decision Decision Tree depth 3 memiliki performa terbaik pada seluruh metrik data uji. Perbedaan akurasi latih dan uji hanya sebesar 0,01, sementara pohon penuh mengalami penurunan dari 1,00 menjadi 0,69 yang mengindikasikan terjadinya overfitting.


3. Confusion Matrix



Gambar 2. Confusion matrix ketiga model.

Decision Tree depth 3 menghasilkan 40 true negative, 13 false positive, 10 false negative, dan 37 true positive. Pohon penuh menghasilkan 18 false negative, sedangkan Gaussian Naive Bayes menghasilkan 16 false negative. Dengan kelas Ya sebagai kelas positif, Decision Tree depth 3 paling sedikit gagal mengidentifikasi mahasiswa yang benar-benar lulus tepat waktu. Dalam penerapan sistem peringatan dini, recall kelas Tidak tetap perlu diperhatikan karena kelas tersebut menunjukkan mahasiswa yang berisiko mengalami keterlambatan kelulusan.

4. Visualisasi Decision Tree



Gambar 3. Visualisasi Decision Tree dengan $\text{max_depth}=3$.

Pohon menyajikan aturan prediksi hingga tiga tingkat. Setiap simpul menampilkan fitur, nilai ambang, jumlah data, serta kecenderungan kelas. Struktur yang ringkas menjaga interpretabilitas model sekaligus mengurangi risiko model terlalu menyesuaikan diri terhadap data latih.

5. Analisis Error

Dari 100 data uji, 23 data salah diprediksi oleh Decision Tree $\text{max_depth}=3$. Lima contoh kesalahan ditampilkan pada Tabel 2. Nomor baris menghitung header CSV sebagai baris pertama.

Baris CSV	Aktual	Prediksi	IPK	Kehadiran	Jam Belajar
6	Ya	Tidak	3,07	85,3	11,2
56	Tidak	Ya	3,60	88,8	15,5
105	Tidak	Ya	3,27	74,9	7,4
107	Tidak	Ya	3,70	80,1	11,2
145	Ya	Tidak	3,03	85,5	14,4

Tabel 2. Lima contoh data salah prediksi.

Baris 6 dan 145 diprediksi Tidak, meskipun label aktualnya Ya. Nilai IPK keduanya berada di sekitar 3,0, sehingga model diduga lebih menekankan ambang IPK dan belum sepenuhnya menangkap kontribusi kehadiran maupun jam belajar. Sebaliknya, baris 56, 105, dan 107 diprediksi Ya meskipun aktualnya Tidak. Kombinasi nilai IPK dan fitur lainnya mengarahkan observasi tersebut ke daun dengan mayoritas kelas Ya, sementara label aktual menunjukkan bahwa indikator akademik yang digunakan belum mampu menjelaskan seluruh variasi kelulusan.

Dataset belum mencakup faktor seperti jumlah SKS yang telah diselesaikan, mata kuliah yang diulang, status pekerjaan, kondisi kesehatan, beban keluarga, maupun perubahan IPK

antarsemester. Faktor-faktor tersebut hanya menjadi kemungkinan penjelasan dan bukan temuan langsung dari dataset. Oleh karena itu, kesalahan prediksi tidak dapat langsung dianggap sebagai indikator kegagalan mahasiswa, tetapi perlu ditinjau berdasarkan konteks tambahan dan melalui validasi manusia.

6. Keterbatasan Gaussian Naive Bayes

GaussianNB digunakan sesuai dengan ketentuan tugas, tetapi asumsi distribusi Gaussian kurang sesuai untuk fitur kategorik hasil one-hot encoding yang bersifat biner. Selain itu, adanya korelasi antara IPK dengan Jam Belajar serta Penghasilan Ortu dengan Status Beasiswa berpotensi bertentangan dengan asumsi independensi antarfitur. Kedua kondisi tersebut dapat menjadi salah satu faktor yang menyebabkan performa GaussianNB lebih rendah dibandingkan Decision Tree depth 3.

BAGIAN C: REKOMENDASI DAN ETIKA (KELOMPOK)

1. Rekomendasi Model untuk Kampus

Model yang saya dipilih untuk rekomendasi adalah Decision Tree max_depth=3 karena memperoleh akurasi 0,77, precision 0,74, recall 0,79, dan F1 Score 0,76, yang merupakan performa tertinggi pada data uji. Selisih akurasi antara data latih dan uji yang relatif kecil menunjukkan kemampuan generalisasi yang lebih baik dibandingkan pohon penuh.

Selain memiliki performa kuantitatif yang baik, model juga mudah diinterpretasikan melalui jalur aturan dari akar hingga daun. Model lebih tepat dimanfaatkan sebagai sistem peringatan dini untuk menentukan prioritas pendampingan, bukan sebagai penentu otomatis kelulusan maupun penerima beasiswa. Keputusan akhir tetap memerlukan peninjauan dan pertimbangan dari dosen pembimbing.

2. Bias dan Etika

Penghasilan_Ortu berpotensi menjadi proksi kondisi sosial ekonomi sehingga mahasiswa dari keluarga berpenghasilan rendah dapat dirugikan apabila ketimpangan historis dipelajari sebagai pola kemampuan akademik. Jenis_Kelamin juga berpotensi merefleksikan stereotip atau perbedaan kesempatan yang tidak memiliki hubungan kausal dengan kemampuan belajar.

Mitigasinya dapat dilakukan dengan membandingkan performa model menggunakan dan tanpa fitur sensitif, menghitung metrik berdasarkan kelompok, serta memisahkan kebijakan beasiswa afirmatif dari model prediksi kelulusan. Kampus juga perlu menerapkan peninjauan manusia, mekanisme banding, dokumentasi alasan keputusan, audit secara berkala, serta perlindungan terhadap data mahasiswa.

3. Simulasi IPK Tinggi dan Kehadiran Rendah

Simulasi menggunakan IPK 3,80, Kehadiran 65%, Jam Belajar berdasarkan median dataset, serta modus untuk Organisasi, Penghasilan_Ortu, dan Status_Beasiswa, dengan

Jenis_Kelamin P. Kombinasi ini digunakan untuk menggambarkan mahasiswa dengan capaian akademik tinggi, tetapi memiliki tingkat kehadiran yang relatif rendah. Skenario tersebut penting untuk melihat bagaimana setiap algoritma merespons dua indikator utama yang berlawanan serta mengetahui apakah terdapat fitur tertentu yang terlalu dominan dalam memengaruhi keputusan model.

Model	Prediksi	Peluang Ya
Decision Tree depth 3	Ya	0,55
Decision Tree penuh	Ya	1,00
Gaussian Naive Bayes	Tidak	0,35

Tabel 3. Hasil simulasi satu mahasiswa.

Decision Tree depth 3 memprediksi Ya dengan probabilitas 0,55 karena observasi mengikuti aturan menuju daun yang didominasi kelas Ya. IPK yang tinggi memberikan sinyal positif sehingga tingkat kehadiran yang rendah belum mengubah hasil prediksi. Decision Tree penuh juga memprediksi Ya dengan probabilitas 1,00, tetapi nilai tersebut perlu ditafsirkan secara hati-hati karena model menunjukkan indikasi overfitting pada data latih. Sementara itu, Gaussian Naive Bayes memprediksi Tidak dengan probabilitas kelas Ya sebesar 0,35 karena kehadiran rendah memberikan pengaruh negatif ketika seluruh fitur dihitung dalam probabilitas posterior. Perbedaan hasil tersebut menunjukkan bahwa prediksi tidak hanya ditentukan oleh satu fitur, tetapi juga oleh mekanisme masing-masing algoritma. Oleh karena itu, hasil simulasi perlu diposisikan sebagai bahan analisis dan dikonfirmasi dengan informasi akademik lain, seperti perkembangan IPK, jumlah SKS yang telah lulus, mata kuliah yang diulang, serta kondisi mahasiswa.

KESIMPULAN

Berdasarkan tahapan preprocessing, pemodelan, dan evaluasi, pemilihan algoritma perlu mempertimbangkan tidak hanya akurasi, tetapi juga kemampuan generalisasi dan interpretabilitas model. Setelah melalui penanganan missing value, encoding fitur kategorik, serta pembagian data 80:20 secara terstratifikasi, Decision Tree max_depth=3 menunjukkan performa paling konsisten dengan akurasi uji 0,77 dan selisih akurasi latih-uji hanya 0,01. Hal ini menunjukkan kemampuan generalisasi yang relatif baik serta struktur prediksi yang mudah diinterpretasikan.

Sebaliknya, Decision Tree tanpa pembatasan kedalaman mengalami indikasi overfitting, ditunjukkan oleh akurasi latih 1,00 yang turun menjadi 0,69 pada data uji. Gaussian Naive Bayes memperoleh akurasi 0,70, dengan keterbatasan yang berkaitan dengan asumsi independensi fitur dan distribusi data. Perbedaan hasil simulasi juga menunjukkan bahwa setiap algoritma memiliki mekanisme prediksi yang berbeda, sehingga output model tidak dapat dipandang sebagai kebenaran mutlak.

Dengan demikian, Decision Tree max_depth=3 dapat dimanfaatkan sebagai sistem peringatan dini dan pendukung keputusan, bukan sebagai penentu otomatis terhadap kelulusan atau penerimaan beasiswa. Penggunaan atribut sensitif seperti penghasilan orang tua dan jenis kelamin juga perlu disertai audit fairness, transparansi, pengawasan manusia, serta perlindungan data. Sebelum diterapkan secara nyata, model perlu divalidasi lebih lanjut menggunakan data lintas angkatan, validasi silang, evaluasi antarkelompok, dan pemantauan berkala.

.

.