

**LAPORAN TUGAS MACHINE LEARNING
PREDIKSI KELULUSAN TEPAT WAKTU MAHASISWA
MENGUNAKAN DECISION TREE DAN NAIVE BAYES**



Disusun Oleh

Nama : Muhammad Yusuf Arrayyan
NPM : G1A024009
Kelas : A1

Dosen Pengampu

1. Ir. Arie Vatesia, S.T., M.T.I., Ph.D., IPP

**PROGRAM STUDI INFORMATIKA
FAKULTAS TEKNIK
UNIVERSITAS BENGKULU**

2026

SOAL DAN PEMBAHASAN

DESKRIPSI TUGAS

Kamu adalah seorang Data Scientist di startup EduTech. Perusahaan ingin memprediksi apakah mahasiswa akan LULUS TEPAT WAKTU atau TIDAK. Dataset mahasiswa_lulus.csv berisi 500 data dengan fitur IPK, Kehadiran, Jam_Belajar, Organisasi, Penghasilan_Ortu, Jenis_Kelamin, dan Status_Beasiswa. Tugas terdiri dari Bagian A: Analisis Konsep, Bagian B: Implementasi dan Evaluasi, serta Bagian C: Rekomendasi dan Etika.

BAGIAN A: ANALISIS KONSEP

1. Decision Tree dibandingkan Naive Bayes

Decision Tree lebih cocok ketika pola kelulusan terbentuk dari hubungan tidak linear dan interaksi antarfaktor. Alasan pertama, pohon dapat membentuk aturan bertingkat; misalnya IPK tinggi dapat mengarah ke prediksi lulus, tetapi hasilnya dapat berubah ketika kehadiran sangat rendah. Interaksi tersebut dapat ditangkap tanpa mensyaratkan bentuk distribusi data tertentu.

Alasan kedua, jalur keputusan dari akar sampai daun mudah ditelusuri sehingga alasan prediksi dapat dijelaskan kepada kampus. Transparansi ini penting dalam sistem peringatan dini karena dosen pembimbing dapat memeriksa dasar prediksi sebelum memberikan intervensi kepada mahasiswa.

2. Asumsi independensi pada Naive Bayes

Pasangan pertama adalah IPK dan Jam Belajar. Kebiasaan belajar yang konsisten dapat berkaitan dengan pencapaian akademik, sehingga informasi dari kedua fitur tersebut kemungkinan saling tumpang tindih. Hubungan ini membuat keduanya tidak sepenuhnya independen ketika digunakan untuk memprediksi kelulusan.

Pasangan kedua adalah Penghasilan Ortu dan Status Beasiswa. Penghasilan keluarga sering menjadi salah satu kriteria pemberian beasiswa sehingga kedua fitur kemungkinan saling berhubungan. Naive Bayes dapat memperlakukannya sebagai bukti terpisah dan menghasilkan probabilitas prediksi yang terlalu yakin.

3. Risiko overfitting pada Decision Tree

Pohon tanpa batas kedalaman dapat membuat cabang yang sangat spesifik dan menangkap noise pada data latih. Pada eksperimen ini, Decision Tree penuh memperoleh

akurasi latih 1,00 tetapi akurasi uji hanya 0,69. Kesenjangan tersebut menunjukkan bahwa model cenderung menghafal data latih dan memiliki kemampuan generalisasi yang lemah.

Risiko overfitting dapat dikurangi dengan membatasi `max_depth`, mengatur `min_samples_split` dan `min_samples_leaf`, melakukan cost-complexity pruning, serta memilih parameter melalui validasi silang. Pada tugas ini, pembatasan `max_depth=3` menghasilkan performa uji yang lebih baik sekaligus mempertahankan aturan yang mudah dijelaskan.

BAGIAN B: IMPLEMENTASI DAN EVALUASI

1. Preprocessing dan Pembangunan Model


Dataset mahasiswa_lulus.csv terdiri dari 500 observasi dan delapan kolom. Target `Lulus_Tepat_Waktu` memuat 237 kelas Ya dan 263 kelas Tidak. Nilai hilang ditemukan pada `IPK` sebanyak 20, `Kehadiran` 25, `Jam_Belajar` 30, dan `Penghasilan_Ortu` 15. Fitur numerik diisi dengan median data latih, sedangkan fitur kategorik diisi dengan modus. Organisasi, `Penghasilan_Ortu`, `Jenis_Kelamin`, dan `Status_Beasiswa` dikodekan menggunakan `OneHotEncoder`.

Data dibagi menjadi 400 data latih dan 100 data uji menggunakan rasio 80:20, stratifikasi target, dan `random_state=42`. Tiga model dilatih pada pembagian yang sama, yaitu `DecisionTreeClassifier(max_depth=3)`, `DecisionTreeClassifier(max_depth=None)`, dan `GaussianNB`. Seluruh preprocessing ditempatkan dalam pipeline agar parameter imputasi dan encoding hanya dipelajari dari data latih.

2. Hasil Evaluasi

Model	Akurasi	Precision	Recall	F1	Akurasi Latih
Decision Tree depth 3	0,77	0,74	0,79	0,76	0,78
Decision Tree penuh	0,69	0,69	0,62	0,65	1,00
Gaussian Naive Bayes	0,70	0,69	0,66	0,67	0,76


Tabel 1. Perbandingan performa tiga model.



Gambar 1. Perbandingan metrik evaluasi tiga model.

Decision Tree depth 3 unggul pada seluruh metrik data uji. Selisih akurasi latih dan uji hanya 0,01, sedangkan pohon penuh turun dari 1,00 menjadi 0,69 sehingga menunjukkan overfitting.


3. Confusion Matrix



Gambar 2. Confusion matrix ketiga model.

Decision Tree depth 3 menghasilkan 40 true negative, 13 false positive, 10 false negative, dan 37 true positive. Pohon penuh menghasilkan 18 false negative, sedangkan Gaussian Naive Bayes menghasilkan 16 false negative. Dengan kelas Ya sebagai kelas positif, Decision Tree depth 3 paling sedikit melewatkan mahasiswa yang benar-benar lulus tepat waktu. Untuk penerapan sistem peringatan dini, recall kelas Tidak tetap perlu dipantau karena kelas tersebut mewakili mahasiswa yang berisiko terlambat lulus.

4. Visualisasi Decision Tree



Gambar 3. Visualisasi Decision Tree dengan $\text{max_depth}=3$.

Pohon menampilkan aturan sampai tiga tingkat. Setiap simpul memuat fitur, ambang, jumlah data, dan kecenderungan kelas. Struktur yang pendek mempertahankan interpretabilitas sekaligus mengurangi kecenderungan model menghafal data latih.

5. Analisis Error

Dari 100 data uji, 23 data salah diprediksi oleh Decision Tree $\text{max_depth}=3$. Lima contoh kesalahan ditampilkan pada Tabel 2. Nomor baris menghitung header CSV sebagai baris pertama.

Baris CSV	Aktual	Prediksi	IPK	Kehadiran	Jam Belajar
6	Ya	Tidak	3,07	85,3	11,2
56	Tidak	Ya	3,60	88,8	15,5
105	Tidak	Ya	3,27	74,9	7,4
107	Tidak	Ya	3,70	80,1	11,2
145	Ya	Tidak	3,03	85,5	14,4

Tabel 2. Lima contoh data salah prediksi.

Baris 6 dan 145 diprediksi Tidak walaupun aktualnya Ya. IPK keduanya berada di sekitar 3,0 sehingga model dapat terlalu menekankan ambang IPK dan belum sepenuhnya menangkap pengaruh kompensasi dari kehadiran atau jam belajar. Baris 56, 105, dan 107 diprediksi Ya walaupun aktualnya Tidak. Nilai IPK atau kombinasi fitur membawa observasi

ke daun mayoritas Ya, tetapi label aktual menunjukkan bahwa indikator akademik yang tersedia belum menjelaskan seluruh variasi kelulusan.

Dataset tidak mencakup jumlah SKS lulus, mata kuliah mengulang, status kerja, kesehatan, beban keluarga, maupun perubahan IPK antarsemester. Faktor tersebut hanya merupakan kemungkinan penjelasan, bukan temuan langsung dari data. Karena itu, kesalahan prediksi tidak boleh dianggap sebagai kegagalan mahasiswa dan harus diperiksa melalui konteks tambahan serta validasi manusia.

6. Keterbatasan Gaussian Naive Bayes

GaussianNB digunakan sesuai instruksi tugas, tetapi asumsi distribusi Gaussian kurang ideal untuk fitur kategorik hasil one-hot encoding yang bernilai biner. Selain itu, korelasi IPK dengan Jam Belajar serta Penghasilan Ortu dengan Status Beasiswa dapat melanggar asumsi independensi. Kedua kondisi tersebut mungkin berkontribusi terhadap performanya yang lebih rendah daripada Decision Tree depth 3.

BAGIAN C: REKOMENDASI DAN ETIKA

1. Rekomendasi Model untuk Kampus

Model yang direkomendasikan adalah Decision Tree `max_depth=3` karena memperoleh akurasi 0,77, precision 0,74, recall 0,79, dan F1 Score 0,76, yaitu hasil tertinggi pada data uji. Selisih akurasi latih dan uji yang kecil menunjukkan generalisasi yang lebih baik daripada pohon penuh.

Selain unggul secara kuantitatif, model mudah dijelaskan melalui jalur aturan dari akar sampai daun. Model sebaiknya digunakan sebagai sistem peringatan dini untuk menentukan prioritas pendampingan, bukan sebagai penentu otomatis kelulusan atau beasiswa. Keputusan akhir tetap memerlukan pemeriksaan dosen pembimbing.

2. Bias dan Etika

Penghasilan_Ortu dapat menjadi proksi kelas sosial sehingga mahasiswa dari keluarga berpenghasilan rendah berisiko dirugikan apabila ketimpangan historis dipelajari sebagai pola kemampuan akademik. Jenis_Kelamin juga dapat menangkap stereotip atau perbedaan kesempatan yang tidak berkaitan secara kausal dengan kemampuan belajar.

Mitigasinya adalah membandingkan performa model dengan dan tanpa fitur sensitif, menghitung metrik per kelompok, serta memisahkan kebijakan beasiswa afirmatif dari model

prediksi kelulusan. Kampus juga perlu menerapkan peninjauan manusia, mekanisme banding, pencatatan alasan, audit berkala, dan perlindungan data.

3. Simulasi IPK Tinggi dan Kehadiran Rendah

Simulasi menggunakan IPK 3,80, Kehadiran 65%, Jam Belajar sebesar median dataset, modus untuk Organisasi, Penghasilan_Ortu, dan Status_Beasiswa, serta Jenis_Kelamin P. Kombinasi tersebut dipilih untuk menggambarkan mahasiswa yang memiliki capaian akademik tinggi, tetapi tingkat kehadirannya relatif rendah. Skenario ini penting karena memperlihatkan bagaimana setiap algoritma merespons dua sinyal utama yang saling bertentangan dan apakah satu fitur tertentu terlalu mendominasi keputusan model.

Model	Prediksi	Peluang Ya
Decision Tree depth 3	Ya	0,55
Decision Tree penuh	Ya	1,00
Gaussian Naive Bayes	Tidak	0,35

Tabel 3. Hasil simulasi satu mahasiswa.

Decision Tree depth 3 memprediksi Ya dengan peluang 0,55 karena observasi mengikuti jalur aturan menuju daun yang mayoritas berisi kelas Ya. IPK tinggi memberikan sinyal positif yang cukup kuat sehingga kehadiran rendah belum membalik keputusan. Decision Tree penuh juga memprediksi Ya dengan probabilitas 1,00, tetapi nilai yang sangat ekstrem harus ditafsirkan dengan hati-hati karena model tersebut telah menunjukkan overfitting pada data latih. Gaussian Naive Bayes memprediksi Tidak karena peluang kelas Ya hanya 0,35; kehadiran rendah memberikan bukti negatif ketika kontribusi seluruh fitur dihitung dalam probabilitas posterior. Perbedaan ini menunjukkan bahwa prediksi dipengaruhi mekanisme algoritma, bukan hanya nilai satu fitur. Oleh karena itu, hasil simulasi harus digunakan sebagai bahan analisis dan dikonfirmasi dengan informasi akademik lain, seperti perkembangan IPK, jumlah SKS lulus, mata kuliah mengulang, serta kondisi mahasiswa.

KESIMPULAN

Berdasarkan seluruh tahapan preprocessing, pemodelan, dan evaluasi, penelitian ini menunjukkan bahwa pemilihan algoritma harus didasarkan pada performa data uji, kemampuan generalisasi, serta kemudahan interpretasi. Dataset mahasiswa_lulus.csv telah melalui penanganan missing value, encoding fitur kategorik, dan pembagian data terstratifikasi dengan rasio 80:20. Proses tersebut diperlukan agar ketiga model dapat dibandingkan pada kondisi pengujian yang sama dan hasil evaluasinya dapat dipertanggungjawabkan.

Decision Tree max_depth=3 merupakan model terbaik pada eksperimen ini. Model memperoleh akurasi 0,77, precision 0,74, recall 0,79, dan F1 Score 0,76. Akurasi latih sebesar 0,78 hanya berbeda 0,01 dari akurasi uji sehingga model menunjukkan generalisasi yang relatif stabil. Struktur pohon yang dibatasi juga membuat aturan prediksi lebih mudah ditelusuri dan dijelaskan kepada pihak kampus.

Decision Tree tanpa batas kedalaman mencapai akurasi latih 1,00, tetapi akurasi ujinya turun menjadi 0,69. Kesenjangan tersebut memperlihatkan bahwa pohon penuh menghafal pola data latih, termasuk kemungkinan noise, tanpa menghasilkan peningkatan pada data baru. Gaussian Naive Bayes memperoleh akurasi 0,70 dan menghadapi keterbatasan asumsi independensi antarfitur serta distribusi Gaussian pada fitur kategorik hasil one-hot encoding.

Hasil simulasi mahasiswa dengan IPK tinggi dan kehadiran rendah memperlihatkan bahwa model dapat memberikan keputusan berbeda untuk kombinasi fitur yang sama. Decision Tree mengikuti jalur aturan dan tetap memprediksi lulus tepat waktu, sedangkan Gaussian Naive Bayes menggabungkan kontribusi probabilitas seluruh fitur dan menghasilkan prediksi tidak tepat waktu. Perbedaan ini menegaskan bahwa hasil model harus dipahami bersama cara kerja algoritmanya dan tidak boleh dianggap sebagai kebenaran mutlak.

Dalam penerapan di kampus, Decision Tree max_depth=3 sebaiknya digunakan sebagai sistem peringatan dini dan alat pendukung keputusan, bukan sebagai penentu otomatis kelulusan atau penerima beasiswa. Penggunaan Penghasilan_Ortu dan Jenis_Kelamin memerlukan fairness audit, transparansi, peninjauan manusia, mekanisme banding, serta perlindungan data. Sebelum diterapkan secara nyata, model perlu diuji melalui validasi silang, data angkatan berbeda, evaluasi per kelompok, dan pemantauan berkala agar manfaatnya tidak menimbulkan keputusan yang tidak adil bagi mahasiswa.